huxiaofs

2026-03-29

效果演示文档

本文档用于展示 **md-to-latex-pdf** 的排版效果，涵盖数学公式、中英文混排、代码块、表格等常见学术写作场景。

1 数学公式

1.1 行内公式

设随机变量 $X \sim \mathcal{N}(\mu, \sigma^2)$，其概率密度函数为 $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$。

当 $n \to \infty$ 时，由中心极限定理知 $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1)$。

1.2 展示公式

傅里叶变换与逆变换互为对偶：

$$\hat{f}(\xi) = \int_{-\infty}^{+\infty} f(x)\, e^{-2\pi i x \xi}\, \mathrm{d}x, \qquad f(x) = \int_{-\infty}^{+\infty} \hat{f}(\xi)\, e^{2\pi i x \xi}\, \mathrm{d}\xi$$

梯度下降的参数更新规则（η 为学习率）：

$$\theta_{t+1} = \theta_t - \eta \nabla_\theta \mathcal{L}(\theta_t)$$

注意力机制（Transformer 核心）：

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

矩阵的奇异值分解（SVD）：

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top, \quad \mathbf{\Sigma} = \mathrm{diag}(\sigma_1, \sigma_2, \ldots, \sigma_r), \quad \sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$$

2 中英文混排

深度学习（*Deep Learning*）的兴起使大规模语言模型（Large Language Model，LLM）成为自然语言处理领域的主流范式。以 Transformer 架构为基础，GPT、BERT 等模型通过在海量语料上进行预训练，习得了丰富的语言知识与推理能力。

> 我们所面临的最重要问题，无法在产生这些问题的思维层次上得到解决。
>
> — Albert Einstein

3 表格

表 1　主流大语言模型参数规模对比

模型	机构	参数量	开源
GPT-4	OpenAI	未公开	✗
Claude 3 Opus	Anthropic	未公开	✗
Llama 3 70B	Meta	70B	✓
Qwen2.5 72B	阿里巴巴	72B	✓
DeepSeek-V3	DeepSeek	671B (MoE)	✓

4　代码块

以下是一个用 Python 实现 softmax 函数的示例：

```
import numpy as np

def softmax(x: np.ndarray, axis: int = -1) -> np.ndarray:
    """数值稳定的 softmax 实现。"""
    e_x = np.exp(x - np.max(x, axis=axis, keepdims=True))
    return e_x / e_x.sum(axis=axis, keepdims=True)

# 示例
logits = np.array([2.0, 1.0, 0.1])
probs = softmax(logits)
print(f"概率分布: {probs}")   # [0.659, 0.242, 0.099]
```

5　列表

主要的模型压缩技术包括：

1. **量化（Quantization）**：将浮点权重压缩为低比特整数（INT8 / INT4）
   - 训练后量化（PTQ）：直接对已训练模型施加量化
   - 量化感知训练（QAT）：在训练过程中模拟量化误差
2. **剪枝（Pruning）**：移除冗余权重或结构单元
   - 非结构化剪枝：逐元素稀疏化
   - 结构化剪枝：移除整个注意力头或 FFN 层
3. **知识蒸馏（Knowledge Distillation）**：以大模型为教师指导小模型学习

6　引用与脚注

Vaswani 等人于 2017 年提出的 Transformer 架构[^1]彻底改变了序列建模范式，此后涌现出的 BERT[^2]、GPT 系列等模型均以此为基础。

[^1]: Vaswani, A., et al. (2017). Attention is all you need. *NeurIPS*. [^2]: Devlin, J., et al. (2019). BERT: Pre-training of deep bidirectional transformers. *NAACL*.